Projet Deep Learning

Sujet 2 :

MAYDAY / URGENCY Detector with Transformers

Alexandre Araujo

Bastien Gillino

1 Table des matières

1 Table des matières 2
2 Introduction 3
3 Enregistrement du dataset 4
4 Les modèles de référence 5
4.1 Baseline 1 : Approche par mots clés 5
4.2 Baseline 2 : TF-IDF et la regression logistique 6
5 Le modèle XLM-ROBERTA 8
5.1 Entraînement et test du modèle sur le dataset réduit 8
5.2 Entraînement et test du modèle sur le dataset complet 10
6 Conclusion 11
7 Table des illustrations 12

2 Introduction

Pour ce projet, dans le cadre du module de Deep Learning, nous avons choisi le sujet numéro deux qui vise à créer un système de détection en temps réel des messages d'urgences et de détresses envoyés par les avions.

Dans un monde où le transport par avion est de plus en plus utilisé, il est crucial d'assurer un niveau de sécurité très élevé et ceci passe par la bonne transmission des informations par radios. Malheureusement, les communications radios peuvent être détériorées par de multiples sources de stress ou de bruit qui vont empêcher une bonne compréhension. Le risque est donc que les contrôleurs aériens ne puissent pas réagir à temps ou qu'ils ne prennent pas la bonne décision et que cela se conclu par un suraccident.

Afin d'automatiser et d'assister la détection du niveau d'urgence en temps réel, nous avons construit une pipeline complète. Dans un premier temps, l'on capte l'audio pour ensuite en faire une transcription en texte grâce au modèle Whisper. Enfin, la classification se fait par une intelligence artificielle pré-entrainé, de type Transformers.

Pour cela, nous avons dû créer une base de données suffisamment grande afin d'entrainer, de valider et de tester nos différents modèles. Dans un premier temps, nous avons enregistré environ 300 audios avec 3 voix différentes puis, pour gagner du temps, nous avons utilisé le site ElevenLabs pour créer 700 autres audios et les ajouter à notre dataset initial. Nous avons ensuite comparé des méthodes plus classiques (les deux baselines) avec un modèle de Deep Learning bien plus avancé (XLM-ROBERTA).

3 Enregistrement du dataset

Pour la création de la base de données, nous aurions pu simplement télécharger un dataset déjà fait sur internet mais tous ceux que nous avons trouvé ne répondaient pas à nos attentes. Ils ne comptaient pas assez d'éléments, alors que nous visons environ 1000 audios, ou alors les enregistrements étaient de mauvaise qualité. De plus, la classification des enregistrements n'était jamais bien effectuée. C'est pour ces raisons que nous avons préféré créer notre propre dataset.

Dans un premier temps, nous avons cherché des documents manuscrits en libre accès sur internet qui regroupent un grand nombre de communications radio d'urgences réelles mais sans succès. Plutôt que de créer un tableau avec 1000 lignes à la main en prenant soin de bien indiquer le bon niveau d'urgence et de séparer les différents orateurs, nous avons fait appel à plusieurs intelligences artificielles pour nous aider à définir un dataset correct et sans trop de redondances. Pour cela, nous avons fait appel à *Gemini Pro*, *Claude AI* ou encore *ChatGPT* afin de compléter notre csv tout en respectant les proportions indiquées dans le sujet pour 1000 audios.

Tableau 1 Proportion et répartition des audios au sein du dataset complet

Split	Examples	Share	Normal		Urgency		Distress	
Train	*700*	*70%*	*420*	*60%*	*175*	*25%*	*105*	*15%*
Val	*150*	*15%*	*90*	*60%*	*38*	*25,3%*	*22*	*14,7%*
Test	*150*	*15%*	*90*	*60%*	*37*	*24,7%*	*23*	*15,3%*
Total	*1000*	*100%*	*600*	*60%*	*250*	*25%*	*150*	*15%*

Nous avons aussi spécifié d'inclure quelques pièges dans les messages d'urgences et de détresses. Il s'agit de phrase qui ne possèdent pas de suffixe avec des mots clés mais qui pourtant indique que l'avion est en mauvaise posture. Le but de ces pièges est de faire en sorte que notre modèle ne se concentre pas uniquement sur les mots clés pour classifier les audios. De plus, cela se rapproche de la réalité car il arrive que les pilotes oublient de commencer leurs appels radios par MAYDAY ou PAN PAN en cas de problème.

Afin d'éviter la fuite de données, nous avons fait en sorte que les trois parties du dataset soient enregistrés par des personnes ou des voix différentes. Après analyse du fichier csv, nous avons essayé d'éliminer toutes les similarités entre les phrases d'entrainements et celles de tests pour réduire encore plus le risque de fuite de données.

Dans un premier temps, nous avons effectué une batterie de test sur les 300 enregistrements environ réalisé par nous même pour pouvoir comparer avec les résultats obtenus lorsque le dataset a été complété à l'aide du site *ElevenLabs*. Sur *ElevenLabs*, nous avons utilisé une petite dizaine de voix différentes tout en s'assurant que l'on ne les réutilisait pas ailleurs dans le dataset.

Tableau 2 Répartition des audios au sein du petit dataset

Split	Examples	Share
Train	*200*	*65,4%*
Val	*54*	*17,6%*
Test	*52*	*17%*
Total	*306*	*100%*

4 Les modèles de référence

4.1 Baseline 1 : Approche par mots clés

Il s'agit d'un algorithme très simple qui cherche seulement des mots précis dans le texte. Si la transcription contient « Mayday » ou « Pan Pan », le modèle indiquera qu'il s'agit d'un message de détresse ou d'urgence. En revanche, si aucun de ces mots n'est détecté, alors le message sera classifié comme normal.

Tableau 3 Résultats de la Baseline 1

Nombre d'audios	Nombre d'exemples	Accuracy Globale	Recall (Urgency)	Recall (Distress)	Fausses Alarmes
306	*52*	*75%*	*27%*	*75%*	*0%*
1000	*150*	*79%*	*45%*	*55%*	*0%*

Ces résultats sont très peu concluants et peuvent être expliqué en partie par une mauvaise transcription du modèle Whisper. En effet, lorsque l'on se penche sur les 10 premières transcriptions, on observe que certaines phrases ont été traduites en français. Ceci fausse déjà nos résultats car il se peut que, lors de la traduction, les mots clés disparaissent et notre modèle ne soit pas capable de prédire le bon degré de dangerosité. De plus, une grande quantité des phrases sont des pièges donc ne peuvent pas être bien classé car elles ne contiennent pas de mots clés.

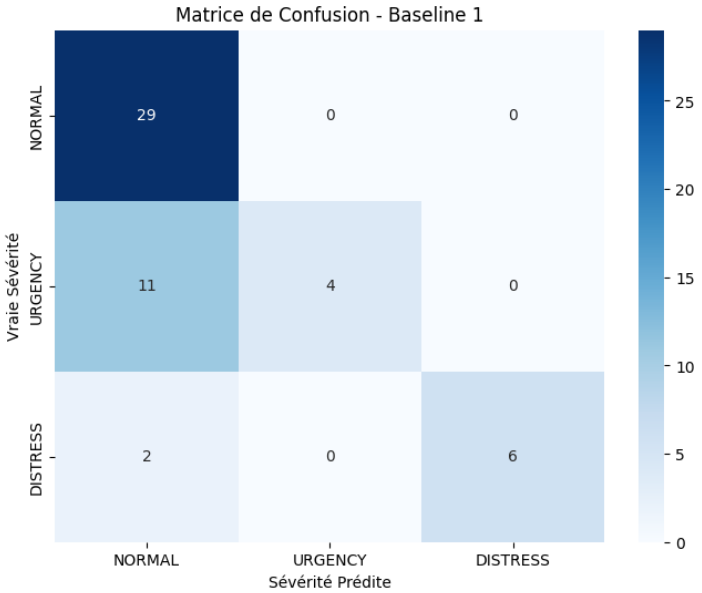

Figure 1 Matrice de confusion de la Baseline 1 sur 52 exemples (petit dataset)

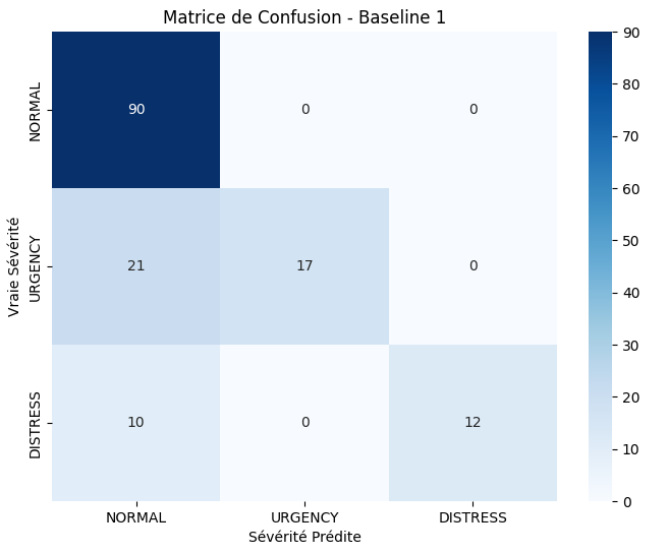

Figure 2 Matrice de confusion de la Baseline 1 sur 150 exemples (dataset complet)

4.2 Baseline 2 : TF-IDF et la regression logistique

Dans cette baseline, on utilise deux méthodes différentes qui se complètent. La première, TF-IDF, est une méthode mathématique qui compte les apparitions d'un même mot dans une phrase. Elle permet de transformer le texte en une suite de chiffres où les mots importants sont mis en avant. Pour la régression logistique, il s'agit d'un algorithme qui apprend à partir des chiffres donnés par la méthode précédente. Il va associer chaque mot à un chiffre et comprendre que les mots qui nous importent, comme « fire » ou « engine » par exemple. Ces mots vont avoir un gros score TF-IDF. En voyant le nombre associé à ces mots importants, le modèle est donc capable de classer les phrases en tant qu'urgence ou détresse.

Le modèle ne tombe plus dans les pièges des phrases sans mots clés car il regarde l'intégralité des mots de chaque phrase. Les résultats s'améliorent donc nettement. Malgré les résultats qui peuvent paraître très bon voire parfait, il faut prendre un peu de recul sur les pourcentages affichés, notamment pour le dataset réduit. En effet, l'entraînement se faisant seulement sur 200 audios et les tests sur 52 autres audios, la probabilité de surapprentissage est très grande ce qui justifie ces résultats « parfaits ». Le modèle à simplement appris le vocabulaire spécifique du dataset car la plupart des phrases sont assez similaires, surtout sur un tout petit échantillon. Il y a toujours un risque qu'il ait appris par cœur une phrase et qu'il tombe sur quelque chose d'extrêmement similaire dans les tests et donc trouve la bonne classification sans vraiment avoir compris pourquoi.

En regardant les résultats sur les 150 exemples, on observe que le Recall pour la détresse descend à 91% car le modèle n'est pas infaillible et surtout il ne fait plus de surapprentissage, ou beaucoup moins. Il s'agit de la limite de ce modèle qui ne comprend pas l'ordre des mots. Par exemple, il n'est pas capable de différencier l'utilisation du mot « engine » entre une phrase normale qui dit que tout va bien et une autre qui dit qu'il ne fonctionne plus.

Tableau 4 Résultats de la Baseline 2

Nombre d'entrainements	Nombre d'exemples	Accuracy Globale	Recall (Urgency)	Recall (Distress)	Fausses Alarmes
200	*52*	*100%*	*100%*	*100%*	*0%*
700	*150*	*99%*	*100%*	*91%*	*0%*

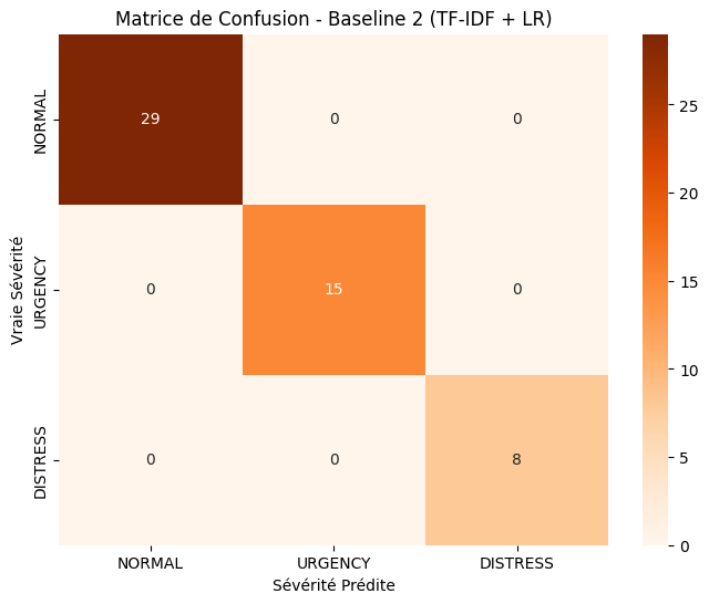

Figure 3 Matrice de confusion de la Baseline 2 sur 52 exemples (petit dataset)

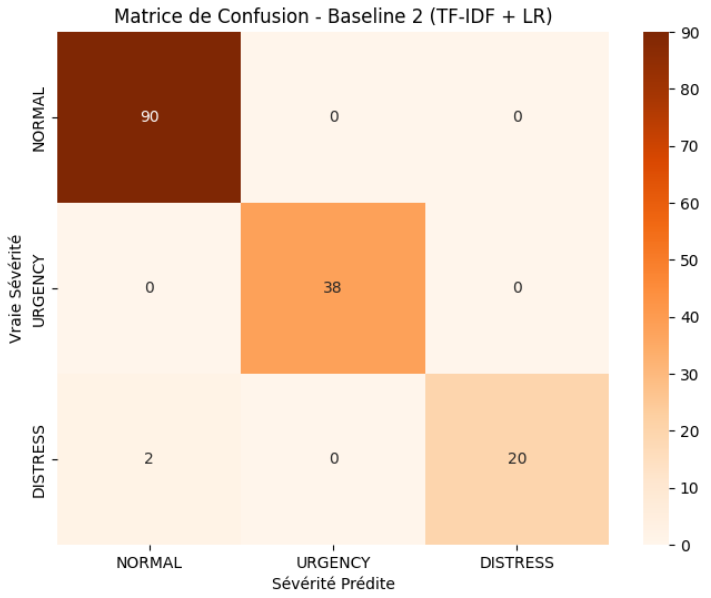

Figure 4 Matrice de confusion de la Baseline 2 sur 150 exemples (dataset complet)

Pour conclure sur la Baseline 2, nous avons vu qu'elle est excellente pour repérer le champ lexical de l'urgence et de la détresse mais il s'agit tout de même d'un modèle naïf. Il s'attarde seulement sur les mots qui ont un gros score TF-IDF sans comprendre le sens global et la grammaire de la phrase.

5 Le modèle XLM-ROBERTA

Dans les parties précédentes, on a pu observer les limites de modèles simples avec la Baseline 1 qui ne cherchait que des mots spécifiques et la Baseline 2 qui ne s'intéresse qu'au poids de chaque mot sans comprendre la phrase. A présent, nous allons travailler avec le modèle XLM-ROBERTA, de type Transformer, qui regarde toute la phrase d'un coup et calcule les relations entre chaque mot. Il s'agit donc d'un modèle capable de comprendre le contexte de chaque phrase. De plus, même en cas d'erreur du modèle Whisper au moment de la transcription, le Transformer est capable de passer outre en devinant le mot initial et son sens grâce aux autres mots de la phrase.

5.1 Entraînement et test du modèle sur le dataset réduit

En lançant le fine-tuning du modèle avec un petit dataset, on s'expose à ce que le modèle fasse de l'overfitting et donc obtenir de meilleurs résultats mais faussés. C'est pour cela que l'on entraine notre modèle sur 5 époques seulement.

Tableau 5 Entraînement du modèle Transformer sur le dataset réduit

Epoch	Validation Loss	Accuracy
1	0.848469	0.685185
2	0.583289	0.796296
3	0.512174	0.796296
4	0.352260	0.796296
5	0.359592	0.814815

Les résultats restent corrects même si le modèle a du mal à s'améliorer entre chaque époque car le nombre d'audios n'est pas suffisamment grand. Au niveau des prédictions sur les 52 exemples, nous obtenons de bons résultats sauf pour le Recall de la détresse qui est à 37,5%. Nous avons ensuite analysé les cinq erreurs faites par notre modèle pour trouver la cause et voir s'il s'agit d'un problème dû à la transcription avec Whisper, ou si simplement le modèle a fait une erreur car il ne s'est pas assez entraîné.

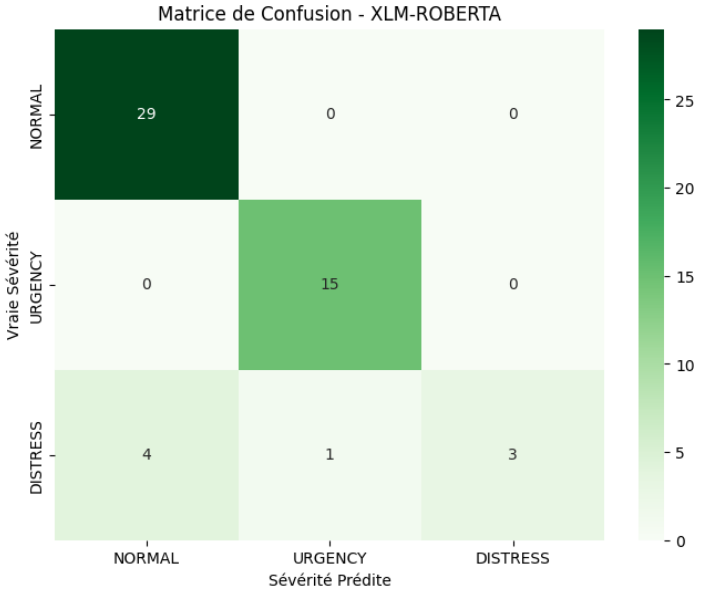

Figure 5 Matrice de confusion du modèle XLM-ROBERTA sur le petit dataset

Tableau 6 Tableau des erreurs après test sur 52 exemples

Whisper text	**True label**	**Prediction**	**Confidence**	**Cause**
Emirate 388 fire confirmed in the right man's gear bay fire visible in on short final cannot retract declaring full emergency	Distress	Normal	0,45	Model
Mayday Mayday, Charlie Echo 55 explosive decompression at flying level 350, oxygen mask deployed descending to 10,000 feet	Distress	Normal	0,61	Model
Mayday, Mayday, Mayday, Sena! 172 uniform! Engine number one on fire and not responding to fire and all. Shutting down! Dervoting to Brussels immediately!	Distress	Urgency	0,43	Model
Mayday Mayday Mayday beach Tango 7 Engine on catastrophically failed Debris striking feels laged Shutting down Diverting to Brussels immediately	Distress	Normal	0,40	Model
Mayday Mayday Mayday United 815 Engine support sighted and wind milling shutting down Diverting to Frankfurt immediately	Distress	Normal	0,52	Model

On peut voir que les cinq erreurs sont dues à un problème de compréhension du modèle qui a mal classé les phrases du Tableau 6. Notre modèle fonctionne donc mais manque bien d'entraînement comme indiqué précédemment. C'est donc pour cela que nous avons augmenté la base de données grâce au site *ElevenLabs* pour atteindre le quota de 1000 audios indiqué dans le sujet.

5.2 Entraînement et test du modèle sur le dataset complet

A présent, nous allons recommencer l'entrainement de notre modèle et comparer ses performances avec celles du dataset réduit.

Tableau 7 Entraînement du modèle Transformer sur le dataset complet

Epoch	Validation Loss	Accuracy
1	0.304229	0.846667
2	0.086202	0.986667
3	0.084446	0.986667
4	0.111072	0.980000
5	0.077508	0.986667

On observe que dès la deuxième époque le modèle comprend la logique et sa précision théorique passe de 84,7% à 98,7%. De même pour la validation loss qui diminue très rapidement et reste basse tout au long du fine-tuning. Cela prouve que notre modèle apprend bien et ne fait pas du « par cœur » contrairement à la deuxième Baseline.

En exécutant la phase de test, nous obtenons 100% de précision globale donc un modèle qui, en théorie, est censé détecter la bonne sévérité pour n'importe quel message.

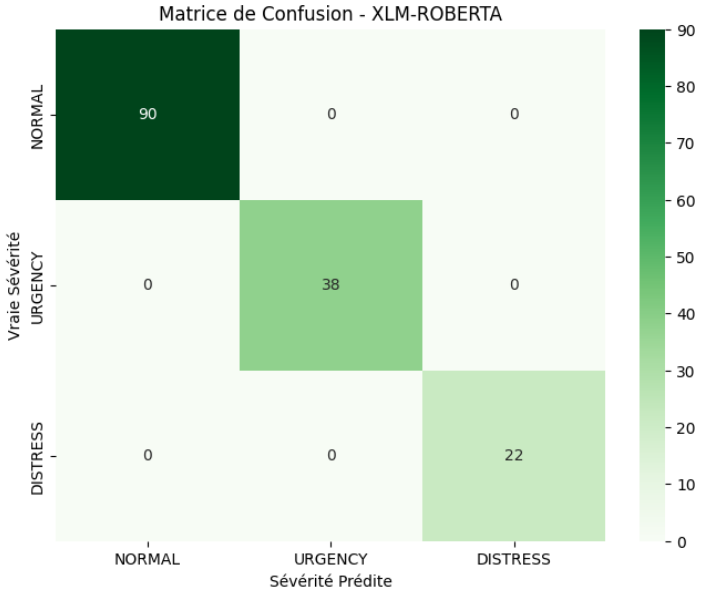

Figure 6 Matrice de confusion du modèle XLM-ROBERTA sur le dataset complet

6 Conclusion

Pour répondre au problème de la sécurité aérienne, nous avons construit une chaine d'intelligence artificielle qui va de la détection depuis le micro jusqu'à la prédiction de la sévérité du message radio.

L'étude des différents modèles a montrée qu'une simple recherche de mots clés n'est largement pas suffisante. L'analyse statique classique était aussi insuffisantes car elle ne prenait pas en compte l'entièreté de sa phrase ainsi que sa grammaire et son sens. En revanche, le modèle Transformer a prouvé son efficacité en donnant une précision théorique de près de 99% car il cherche à comprendre le contexte en étudiant la phrase dans son intégralité.

Le modèle XLM-ROBERTA rempli donc parfaitement les taches qui lui sont demandé car il arrive à détecter les urgences même quand le pilote n'utilise pas de mots clés. De plus, il est résistant au bruit et aux erreurs dû à la transcription du modèle Whisper. Ses excellentes performances en font un candidat idéal pour les tests en temps réel.

Pour aller plus loin et avoir un modèle efficace et exploitable dans la vraie vie, il faudrait remplacer les données de notre dataset par de véritables enregistrements issus de flux ATC. De plus, on pourrait aussi entraîner le modèle XLM-ROBERTA à détecter les urgences même si le pilote se met à parler français ou dans une autre langue commune autre que l'anglais.

7 Table des illustrations

Figure 1 Matrice de confusion de la Baseline 1 sur 52 exemples (petit dataset) 5
Figure 2 Matrice de confusion de la Baseline 1 sur 150 exemples (dataset complet) 6
Figure 3 Matrice de confusion de la Baseline 2 sur 52 exemples (petit dataset) 7
Figure 4 Matrice de confusion de la Baseline 2 sur 150 exemples (dataset complet) 7
Figure 5 Matrice de confusion du modèle XLM-ROBERTA sur le petit dataset 9
Figure 6 Matrice de confusion du modèle XLM-ROBERTA sur le dataset complet 10